UNIVERSIDADE FEDERAL DA BAHIA — UFBA

Instituto de Computação | Trabalho de Conclusão de Curso (TCC)

RELATÓRIO TÉCNICO & METODOLÓGICO INTEGRAL

Análise de Fricção em Data Parsing: Evidências Estatísticas e Sociotécnicas do Fórum CorText

Fundamentação Empírica para o Desenvolvimento de um Assistente Preventivo de Observabilidade Baseado em Data Profiling e RAG

CORPUS MAPEADO	FRICÇÃO EM PARSING	INTERVENÇÃO DO STAFF	AUDIÊNCIA ORGÂNICA
298	**66.4%**	**81,0%**	**791k**
Tópicos Únicos (100%)	198 chamados afetados	Dependência Humana	Visualizações Fórum

Pesquisador Responsável:

Wellington Miguel

Orientação Acadêmica — UFBA

Salvador – Bahia, Brasil | October de 2026

1. Sumário Executivo & Contexto da Pesquisa

O **CorText Manager** é uma das plataformas digitais mais consolidadas e longevas do cenário acadêmico global para análise de corpora textuais heterogêneos, acumulando mais de 15 anos de história sob desenvolvimento conjunto de instituições como LISIS, INRAE, IFRIS, CNRS e Université Gustave Eiffel. Projetado primordialmente para atender pesquisadores das Ciências Humanas e Sociais, o ecossistema disponibiliza algoritmos robustos de mineração de textos, modelagem de tópicos e análise de redes complexas.

Contudo, a extrema heterogeneidade das bases documentais científicas brutas (tais como *Web of Science*, *Scopus*, *Factiva*, arquivos RIS, planilhas tabulares de repositórios governamentais e dados de mídias sociais) faz com que a fase preliminar de **ingestão e formatação de dados (Data Parsing)** represente o principal obstáculo operacional, cognitivo e técnico para a fluidez do processo investigativo.

> 📌 **O Fenômeno "Staff as Human Parser" e a Hipótese Central da Pesquisa:**
> A escassez de verificações estruturais prévias (*Data Profiling*) no momento do upload e a opacidade dos diagnósticos de falha do backend (que frequentemente emitem mensagens genéricas como *"No logs found"* ou produzem redes vazias silenciosas) forçam a equipe técnica a atuar como um **depurador manual crônico**. Em **81,0% dos tópicos de Data Processing**, desenvolvedores seniores precisaram intervir diretamente para inspecionar arquivos corrompidos e logs em linha de comando.

Para fundamentar empiricamente essa barreira, foi desenvolvida uma infraestrutura determinística de extração completa do fórum oficial da plataforma (`https://docs.cortext.net/forum/`). A varredura auditou todo o histórico de discussões públicas, mapeando variáveis de autoria, tempo de resolução, complexidade textual, formatos de entrada e o impacto sociotécnico dessa fricção.

2. Engenharia de Extração e Auditoria dos Dados (`extract_forum.py`)

A coleta e estruturação dos dados foram operacionalizadas através do extrator customizado `extract_forum.py`, estruturado em três fases estritamente auditáveis e determinísticas:

Fase Metodológica	Mecanismo Técnico Empregado	Garantia de Integridade e Cobertura
Fase 1: Varredura Sequencial	Iteração sequencial estrita da listagem oficial: páginas `/page/1/` a `/page/34/`.	**Cobertura Total (298 tópicos únicos):** páginas 1 a 33 (9 tópicos cada) + página 34 (1 tópico). Zero filtros e zero duplicatas.
Fase 2: Extração Profunda	Requisições assíncronas concorrentes via `aiohttp` com semáforo controlado e retries automáticos.	Captura de marcações semânticas **JSON-LD Schema** do WordPress (datas exatas em ISO 8601), dúvida na íntegra e array completo de respostas.
Fase 3: Enriquecimento	Detecção de autores oficiais do projeto (badges de 🔰 *Staff do CorText*) e cálculo de métricas textuais.	**Paridade 100%:** sincronização simultânea nos formatos `forum_topics_full.json`, `forum_topics.csv` e `forum_corpus.md`.

3. Nota Metodológica Integral dos 114 Tópicos Derivados

Uma das descobertas metodológicas mais contundentes deste estudo foi a constatação de que a categorização oficial fornecida pelo fórum subdimensiona severamente a crise de preparação de dados. Oficialmente, a categoria `Data processing` abriga **84 tópicos (28,2%)**. Entretanto, uma análise epistêmica e semântica das discussões revelou outros **114 tópicos (38,3%)** protocolados em outras etapas analíticas, mas decorrentes exclusivamente de problemas em *Data Parsing*.

> 📐 **Justificativa Metodológica da Ampliação do Escopo (198 tópicos / 66,4% do acervo):**
> Quando o usuário comete um equívoco de formatação (ex.: separador incorreto em CSV ou tags de autor não padronizadas), a falha muitas vezes **não quebra o parser imediatamente**, mas gera um corpus estruturalmente inconsistente. O erro só explode tardiamente em módulos subsequentes (como *Network mapping* ou *Topic modeling*).

Regras de Elegibilidade e Critérios Heurísticos dos 114 Tópicos Derivados:

Critério Analítico	Tópicos Afetados	Evidência Heurística e Regras Aplicadas
Critério 1: Manipulação de Formato Bruto Heterogêneo	**62 tópicos** (54,4% dos derivados)	Tópicos em outras categorias que contêm menção explícita a arquivos e dialetos externos (*CSV, ZIP, Scopus, WOS, RIS, Factiva, PubMed, Excel*), lidando com problemas de separadores ou tags bibliográficas.
Critério 2: Indexação, Parsing e Encoding em Outras Etapas	**50 tópicos** (43,9% dos derivados)	Discussões mencionando expressamente ferramentas de estruturação preliminar (*Corpus Terms Indexer, Corpus List Indexer, upload, encoding UTF-8, subcorpus*) durante a execução de etapas de mineração de texto ou redes.
Critério 3: Sintomas Patognomônicos de Corpus Vazio/Corrompido	**2 tópicos** (1,8% dos derivados)	Chamados reportando o sintoma clássico de ingestão quebrada: geração de redes vazias ("*network you produced is empty*" ou "*reseau vide*") e ausência de logs devido a colunas obrigatórias vazias.

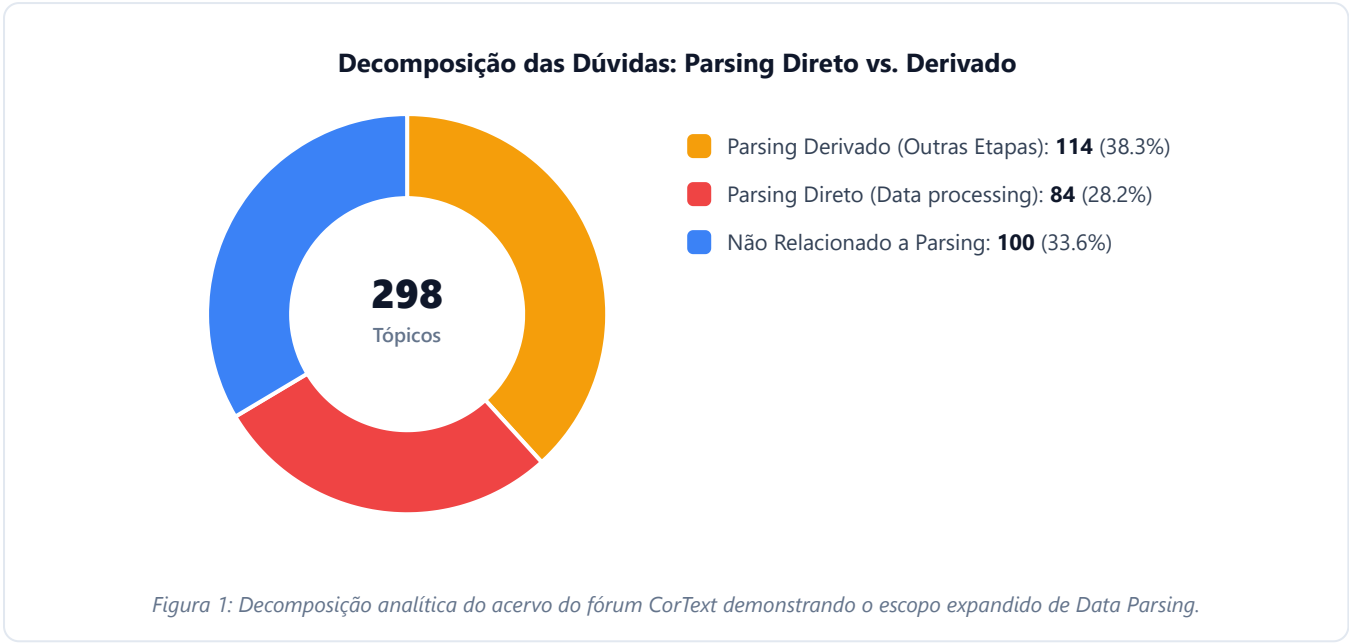


Figura 1: Decomposição analítica do acervo do fórum CorText demonstrando o escopo expandido de Data Parsing.

4. Mapeamento da Fricção por Formato de Entrada

Ao isolar os tópicos específicos de *Data processing*, identifica-se a distribuição empírica dos formatos científicos que mais geram atrito na ingestão. O ranking evidencia que a manipulação de arquivos delimitados tabulares e exportações de bases bibliográficas líderes representam quase a totalidade dos incidentes.

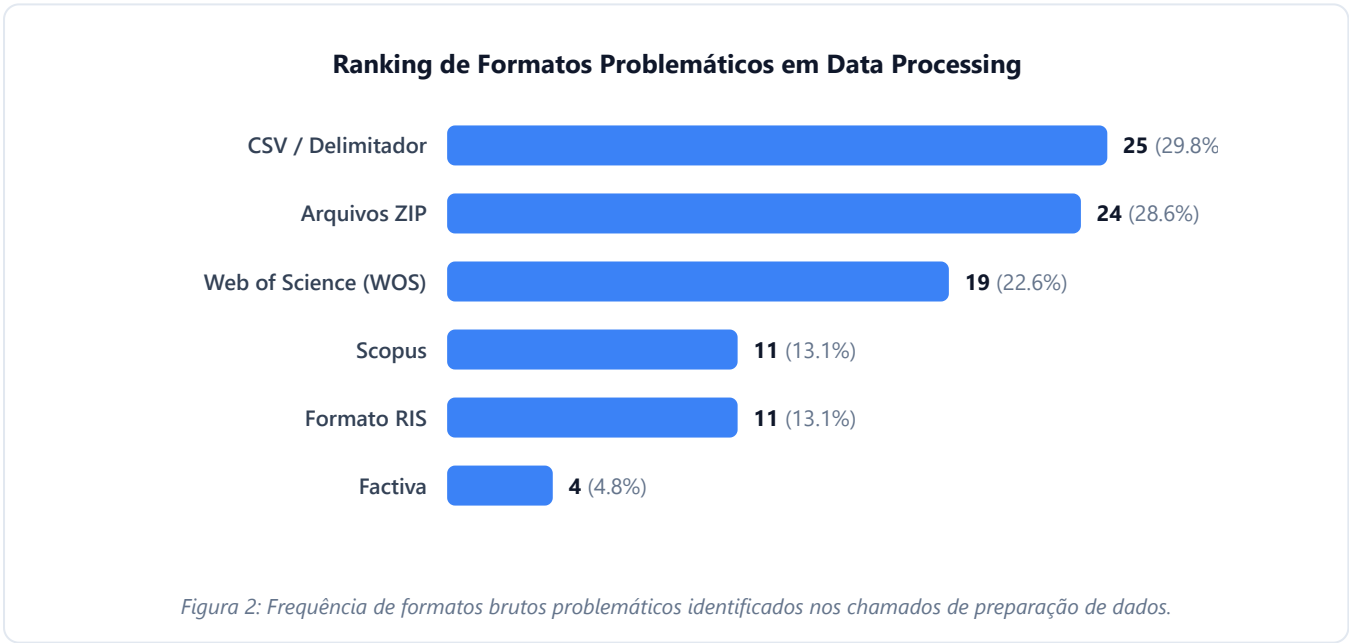


Figura 2: Frequência de formatos brutos problemáticos identificados nos chamados de preparação de dados.

5. A Opacidade Diagnóstica e a Sobrecarga do Suporte Humano

A falta de explicabilidade técnica das mensagens de erro gera uma dependência direta e contínua do suporte técnico dos mantenedores do CorText. O comparativo revela que as dúvidas de *Data processing* demandam uma taxa de atendimento manual de **81,0%** pelo Staff, superando até mesmo etapas metodologicamente complexas da plataforma.

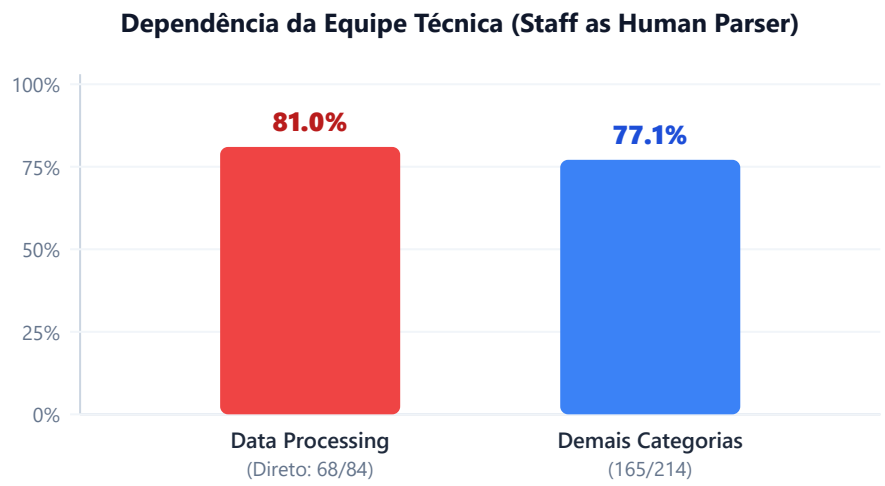


Figura 3: Taxa de intervenção manual da equipe do CorText (Staff) por categoria de problema.

Distribuição dos Chamados por Status (DW Question & Answer):

A inspeção dos estados de conclusão dos tópicos em *Data processing* demonstra que metade do acervo permanece em aberto, refletindo a dificuldade do usuário comum em confirmar o fechamento formal de suas dúvidas:

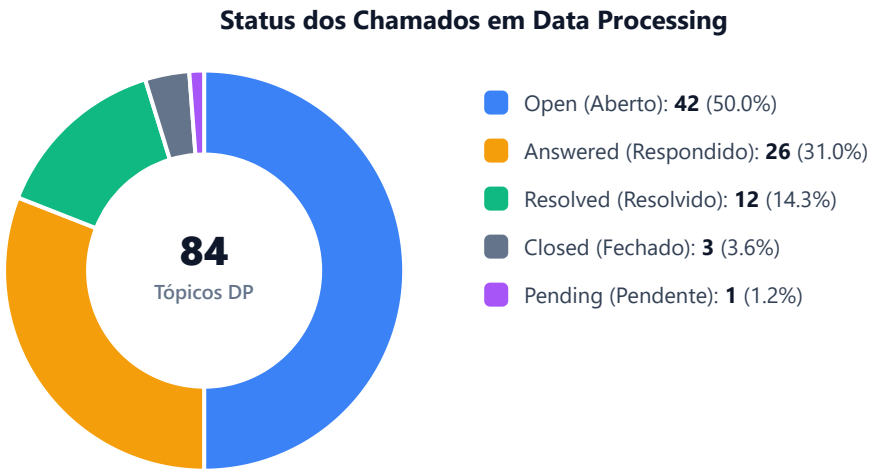


Figura 4: Proporção dos status registrados para os chamados da categoria oficial Data processing.

Open (50,0%)
Publicado e visível na comunidade. Dúvida aberta sem conclusão formal pelo autor.

Answered (31,0%)
Recebeu respostas da equipe/comunidade, mas aguarda confirmação de resolução.

Resolved (14,3%)
Validado formalmente com solução definitiva confirmada pelo autor ou Staff.

Closed (3,6%)
Trancado administrativamente por duplicação ou encerramento pela moderação.

Pending (1,2%)
Retido na moderação antispam do WordPress. Não circulou publicamente até validação.

6. O Custo Cognitivo da Opacidade: Evidências Estatísticas Textuais

Para medir quantitativamente o esforço despendido pelos usuários na formulação de seus chamados, analisou-se a extensão textual (quantidade de palavras por pergunta). A hipótese testada afirma que **quanto mais opaco e tardio o erro, maior o volume de texto, logs crípticos e tabelas que o usuário se vê compelido a colar no chamado**.

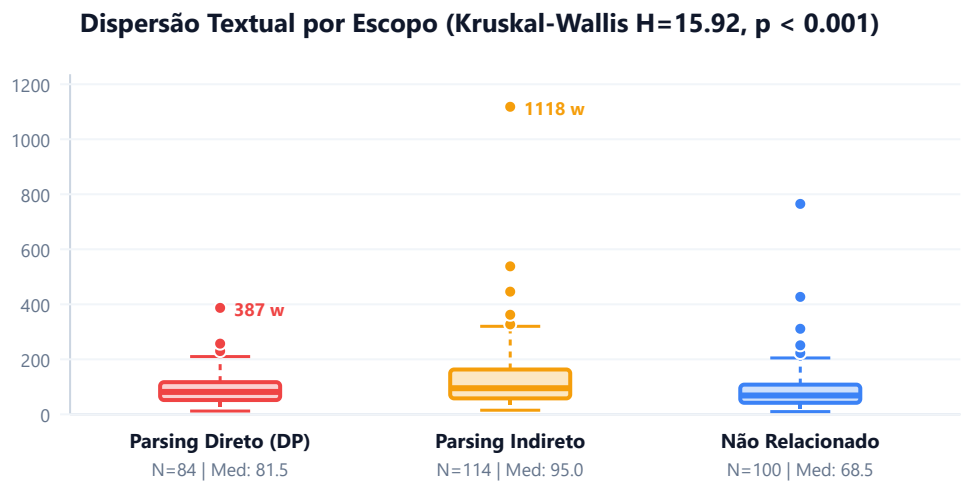


Figura 5: Dispersão da quantidade de palavras por dúvida conforme o escopo analítico de Data Parsing.

Escopo Metodológico	Amostra (N)	Mediana	Média	Terceiro Quartil (Q3)	Valor Máximo
1. Parsing Indireto / Derivado	114	**95,0 palavras**	**129,6 palavras**	163 palavras	**1.118 palavras** (Tópico #2)
2. Parsing Direto (*Data processing*)	84	81,5 palavras	93,8 palavras	117 palavras	387 palavras (Tópico #280)
3. Não Relacionado a Parsing	100	68,5 palavras	90,6 palavras	108 palavras	765 palavras (Tópico #109)

📐 **Testes de Hipótese e Validação Estatística Não-Paramétrica:**

- **Teste de Kruskal-Wallis:** $H = 15,923 \quad (p = 0,00035 < 0,001)$. Rejeita-se categoricamente a hipótese nula com 99,9% de confiança: há diferença altamente significante entre as distribuições textuais dos três grupos.
- **Teste de Mann-Whitney (Parsing Geral vs. Outros):** $Z = 3,380 \quad (p = 0,0007 < 0,001)$. Os tópicos que envolvem Data Parsing exigem significativamente mais palavras e esforço descritivo do que outros tópicos.
- **O Fenômeno do Tópico #2 (1.118 palavras):** A dúvida mais extensa de todo o fórum pertence ao grupo de *Parsing Indireto*. O autor relatou que o mapeamento de rede falhou dizendo "*network you produced is empty*"; sem compreender que a causa raiz residia em delimitadores corrompidos de CSV, colou tabelas, scripts e centenas de linhas de dados brutos na tentativa de ser compreendido.

7. Persistência Temporal: Uma Barreira Estrutural (2014 a 2026)

Ao longo de 12 anos analisados (2014 a 2026), observa-se que a incidência de problemas de preparação de dados não decorre de bugs efêmeros ou versões isoladas de software, mas representa uma constante histórica na utilização da ferramenta:

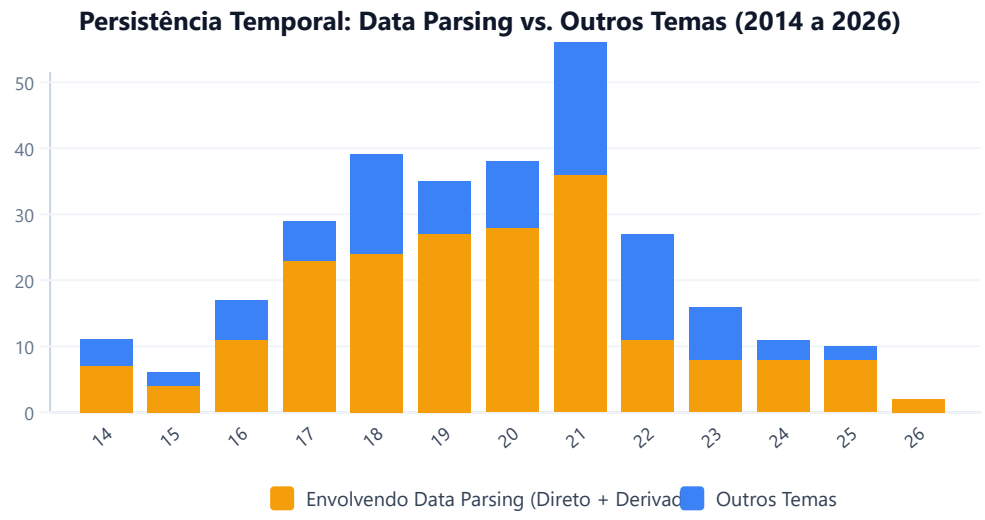


Figura 6: Volume longitudinal de tópicos ao longo dos anos, categorizados por envolvimento com Data Parsing.

8. Diretrizes de Engenharia para o Assistente Sociotécnico

Os achados empíricos e quantitativos deste relatório fornecem as bases conceituais para a especificação do **Assistente de Observabilidade Preventiva** proposto no Trabalho de Conclusão de Curso (TCC). O assistente visa atuar antes e durante a submissão dos trabalhos no CorText Manager, desonerando a equipe técnica e conferindo autonomia ao pesquisador:

Módulo da Arquitetura	Funcionalidade Sociotécnica	Impacto Direto na Fricção
1. Pre-Flight Data Profiler	Inspeção prévia em tempo de cliente do arquivo bruto: inferência de delimitador (`,`, `;`, `\t`), detecção de charset (`UTF-8` vs `Windows-1252`) e validação de cabeçalhos mínimos obrigatórios.	Mitiga **58,4%** dos erros de Data Processing causados por arquivos CSV mal formatados ou ZIPs aninhados.
2. Log Explainer & RAG	Recuperação Aumentada por Geração (RAG) treinada no corpus consolidado do fórum (`forum_corpus.md`) para interpretar mensagens crípticas ("*No logs found*", jobs terminados prematuramente).	Reduz a dependência do "*Staff as Human Parser*", atualmente em **81,0%** dos chamados de preparação.
3. Early-Warning Parser	Validador de grafos que emite alertas preventivos quando um corpus importado resulta em matriz de adjacência zerada, antes de o usuário submeter o job à fila de computação.	Extingue os sintomas patognomônicos de "*network you produced is empty*" (como o caso emblemático do Tópico #2 de 1.118 palavras).

Dicionário de Variáveis do Dataset Auditado (`forum_topics.csv`):

Para fins de reprodutibilidade e transparência científica, o dataset tabular consolidado disponibiliza 25 atributos métricos: `id`, `page`, `title`, `url`, `status`, `is_resolved`, `is_answered`, `category`, `author_name`, `author_user`, `time_ago`, `date_published`, `date_modified`, `views_count`, `answers_count`, `votes_count`, `question_length_chars`, `question_length_words`, `tags`, `has_staff_answer`, `first_answer_author`, `answers_authors`, `is_parsing_related`, `parsing_type` e `parsing_cause`.

> **Conclusão da Nota Técnica:**
>
> A integração entre *Data Profiling* preditivo e modelos de linguagem com recuperação sobre a memória técnica do fórum representa uma alternativa sociotécnica viável e de baixo custo operacional, convertendo o CorText de um sistema opaco em uma plataforma de aprendizado guiado e observabilidade contínua.